



Universidad Internacional de La Rioja
Escuela Superior de Ingeniería y
Tecnología

Máster Universitario en Inteligencia artificial

Aprendizaje de estilos de juego en ajedrez mediante modelos de Machine Learning y grafos temporales dinámicos

Trabajo fin de estudio presentado por:	Alexandre Corcia Aguilera
Tipo de trabajo:	Comparativa de soluciones
Director/a:	Xiomara Patricia Blanco Valencia
Fecha:	22/07/2026

Resumen

Este Trabajo Fin de Estudios se centra en el análisis y aprendizaje de estilos de juego en ajedrez utilizando técnicas de inteligencia artificial. El objetivo principal es identificar patrones que permitan diferenciar distintos estilos de juego a partir de partidas reales, así como evaluar qué enfoques son más adecuados para modelarlos desde una perspectiva computacional.

Para ello, se plantea una comparativa de soluciones entre modelos clásicos de aprendizaje automático, representaciones temporales basadas en fases de partida y una primera aproximación basada en grafos de posiciones. La metodología combina la recopilación de partidas históricas en formato PGN, la extracción de características relevantes y la aplicación de modelos supervisados de clasificación. Entre las características utilizadas se incluyen métricas agregadas de partida, información asociada a aperturas, variables temporales por fases de juego y relaciones estructurales entre piezas.

A partir de esta comparación, se analiza la capacidad de cada representación para capturar diferencias entre estilos de juego. Los resultados muestran que las estadísticas globales permiten identificar ciertos patrones generales, aunque presentan limitaciones para separar estilos estratégicamente similares. La incorporación de información temporal mejora parcialmente la clasificación, mientras que la representación basada en grafos aporta una primera evidencia del valor de las relaciones estructurales entre piezas.

Palabras clave: aprendizaje automático, ajedrez, estilos de juego, representación temporal, redes neuronales sobre grafos.

Abstract

This Final Degree Project focuses on the analysis and learning of chess playing styles using artificial intelligence techniques. The main objective is to identify patterns that allow different playing styles to be distinguished from real games, as well as to evaluate which approaches are more suitable for modeling them from a computational perspective.

To achieve this, the work proposes a comparative study of different solutions, including traditional machine learning models, temporal representations based on game phases, and a first approach based on position graphs. The methodology combines the collection of historical games in PGN format, the extraction of relevant features, and the application of supervised classification models. The features considered include aggregated game metrics, opening-related information, temporal variables by game phase, and structural relationships between pieces.

Based on this comparison, the ability of each representation to capture differences between playing styles is analyzed. The results show that global statistics can identify certain general patterns, although they present limitations when separating strategically similar styles. The incorporation of temporal information partially improves classification performance, while the graph-based representation provides initial evidence of the value of structural relationships between pieces.

Keywords: machine learning, chess, playing styles, temporal representation, graph neural networks.

Índice de contenidos

1. Introducción	1
1.1. Motivación	1
1.2. Planteamiento del trabajo	2
1.3. Estructura del trabajo	3
2. Contexto y estado del arte	4
2.1. Contexto del problema	5
2.2. Estado del arte	7
2.2.1. Aprendizaje autónomo en ajedrez mediante aprendizaje por refuerzo profundo	7
2.2.2. Clasificación de estilos de juego en ajedrez mediante técnicas de aprendizaje automático	10
2.2.3. Predicción de movimientos humanos en ajedrez mediante aprendizaje automático	13
2.2.4. Modelado de grafos temporales dinámicos mediante redes neuronales	15
2.2.5. Revisión de técnicas de aprendizaje en grafos dinámicos	17
2.2.6. Representación basada en grafos en ajedrez.....	20
2.3. Marco teorico	22
2.3.1. Aprendizaje automático supervisado	22
2.3.2. Modelos clásicos de clasificación	23
2.3.3. Optimización de hiperparámetros	24
2.3.4. Métricas de evaluación.....	25
2.3.5. Grafos temporales dinámicos.....	26
2.4. Conclusiones	29
3. Objetivos concretos y metodología de trabajo.....	31

3.1.	Objetivo general.....	31
3.2.	Objetivos específicos	32
3.3.	Metodología del trabajo	33
4.	Desarrollo específico de la contribución	35
4.1.	Construcción del conjunto de datos	36
4.2.	Preprocesamiento y extracción de características	37
4.3.	Análisis exploratorio del conjunto de datos	38
4.4.	Diseño experimental.....	39
4.5.	Modelos clásicos con características agregadas.....	41
4.6.	Modelos clásicos con características temporales.....	44
4.7.	Modelos basados en grafos de posiciones	46
4.7.1.	GCN con agregación a nivel de partida	46
4.7.2.	GCN temporal con GRU	48
4.8.	Experimento de generalización entre jugadores.....	49
4.9.	Comparativa global y análisis de resultados.....	51
5.	Conclusiones y trabajo futuro	53
5.1.	Conclusiones	53
5.2.	Líneas de trabajo futuro	56
	Declaración de uso de Inteligencia Artificial generativa	57
	Referencias bibliográficas.....	58
	Anexo A. Código fuente y datos analizados	

Índice de tablas

Tabla 1. Principales enfoques para el aprendizaje en grafos dinámicos.	20
Tabla 2. Distribución de partidas por jugador y estilo.	37
Tabla 3. Valores medios de los indicadores de actividad por estilo.	39
Tabla 4. Hiperparámetros seleccionados para la regresión logística.	42
Tabla 5. Hiperparámetros seleccionados para Random Forest (características agregadas).	43
Tabla 6. Hiperparámetros seleccionados para XGBoost (características agregadas).	44
Tabla 7. Hiperparámetros seleccionados para Random Forest (características temporales).	45
Tabla 8. Hiperparámetros seleccionados para XGBoost (características temporales).	46
Tabla 9. Hiperparámetros seleccionados para el modelo GCN con agregación a nivel de partida.	48
Tabla 10. Hiperparámetros seleccionados para el modelo temporal GCN+GRU.	49
Tabla 11. Predicción mayoritaria en la validación leave-one-player-out (características agregadas).	50
Tabla 12. Comparativa global de modelos en igualdad de condiciones, ordenada por F1- macro.	52

1. INTRODUCCIÓN

1.1.MOTIVACIÓN

Se suele decir que el número de posibles partidas de ajedrez es mayor que el número de átomos en el universo observable. Más allá de la exactitud de la cifra, esta idea refleja bien la enorme complejidad del juego y ayuda a entender por qué el ajedrez ha sido, durante décadas, uno de los principales campos de estudio en inteligencia artificial.

Desde los primeros programas capaces de jugar partidas completas hasta los sistemas actuales basados en aprendizaje profundo, el ajedrez ha servido como un entorno ideal para desarrollar y evaluar nuevas técnicas. Sin embargo, la mayoría de estos avances se han centrado en mejorar el rendimiento o encontrar la mejor jugada posible en cada posición, dejando en un segundo plano una dimensión igualmente interesante: cómo juegan las personas.

El estilo de juego es un concepto que va más allá de la calidad objetiva de las jugadas. Jugadores distintos pueden llegar a posiciones similares a través de caminos completamente diferentes, reflejando preferencias estratégicas, formas de asumir el riesgo o maneras de interpretar el juego. Algunos optan por posiciones abiertas y tácticas, mientras que otros prefieren estructuras más cerradas y controladas. Estas diferencias, aunque fácilmente reconocibles por jugadores experimentados, no son sencillas de formalizar desde un punto de vista computacional.

En los últimos años, el crecimiento en la disponibilidad de datos, (millones de partidas almacenadas en bases pública) junto con el desarrollo de técnicas de aprendizaje automático, ha abierto nuevas posibilidades para abordar este problema. En este contexto, surge la motivación de este trabajo: explorar hasta qué punto es posible identificar y modelar estilos de juego de forma automática, utilizando herramientas de inteligencia artificial que permitan ir más allá de un análisis puramente superficial de las partidas.

1.2.PLANTEAMIENTO DEL TRABAJO

A partir de esta motivación, el presente trabajo se plantea como un estudio orientado al análisis de estilos de juego en ajedrez desde una perspectiva computacional. En concreto, se propone desarrollar un enfoque que permita representar partidas de ajedrez de forma estructurada y extraer de ellas información relevante para la identificación de patrones de comportamiento.

Para ello, se comparan distintos modelos de aprendizaje automático. Por un lado, se utilizarán enfoques tradicionales que trabajan con representaciones más estáticas de las partidas. Por otro, se explorará un enfoque basado en grafos temporales dinámicos, que permite modelar la partida como una secuencia de estados conectados entre sí, capturando tanto la evolución temporal como las relaciones entre las posiciones.

Esta diferencia en la forma de representar la información puede ser clave para identificar estilos de juego. El objetivo del trabajo no se limita a aplicar diferentes técnicas, sino a analizar en profundidad sus capacidades, comparando sus resultados y evaluando sus ventajas y limitaciones.

1.3. ESTRUCTURA DEL TRABAJO

El presente Trabajo Fin de Estudios se organiza en cinco capítulos.

El primer capítulo, presenta la motivación del estudio, el planteamiento del problema y la estructura del documento. En concreto, se introduce el análisis de estilos de juego en ajedrez desde una perspectiva computacional.

El segundo capítulo aborda el contexto y el estado del arte. Se revisan los trabajos previos más relevantes, desde los enfoques orientados al rendimiento del juego hasta los centrados en el comportamiento humano y en las representaciones basadas en grafos. Además, se establece el marco teórico de las técnicas empleadas, que incluye el aprendizaje supervisado, los modelos clásicos de clasificación, la optimización de hiperparámetros, las métricas de evaluación y los grafos temporales dinámicos, incluidas las redes neuronales sobre grafos y los modelos de secuencia.

El tercer capítulo define el objetivo general y los objetivos específicos del trabajo. Además, describe la metodología seguida, desde la recopilación y el preprocesado de las partidas hasta la evaluación comparativa de los modelos.

El cuarto capítulo constituye el desarrollo específico de la contribución. En él se describen la construcción del conjunto de datos, la extracción de las tres representaciones consideradas —agregada, temporal por fases y estructural basada en grafos—, el análisis exploratorio y el diseño experimental. A continuación, se presentan los resultados de cada familia de modelos, un experimento de generalización entre jugadores y una comparativa global de todos los enfoques en igualdad de condiciones.

El quinto y último capítulo contiene las conclusiones del trabajo, y se muestra el alcance de los objetivos planteados, además de las principales líneas de trabajo futuro.

2. CONTEXTO Y ESTADO DEL ARTE

El ajedrez, además de ser un juego ampliamente estudiado desde el punto de vista computacional, constituye un entorno especialmente interesante para el análisis del comportamiento y la toma de decisiones, lo que lo convierte en un dominio idóneo para la aplicación de técnicas de inteligencia artificial.

En los últimos años, el avance de los modelos de machine learning ha permitido abordar problemas cada vez más complejos dentro de este ámbito, no solo en términos de rendimiento de juego, sino también en el estudio de patrones estratégicos y estilos de juego. Sin embargo, a pesar de estos avances, el análisis del estilo de juego sigue siendo un problema abierto, especialmente cuando se pretende capturar su naturaleza dinámica y evolutiva a lo largo del tiempo.

En este contexto, han comenzado a surgir nuevas aproximaciones que buscan modelar este tipo de información de manera más completa, como las representaciones basadas en grafos dinámicos. Estas permiten describir relaciones entre elementos y observar cómo dichas relaciones cambian a lo largo del tiempo.

A lo largo de este capítulo se abordará, en primer lugar, el contexto del problema, describiendo los elementos fundamentales del dominio de estudio. Posteriormente, se revisarán las principales contribuciones existentes en la literatura, analizando distintas aproximaciones propuestas en trabajos previos. Finalmente, se presentará una síntesis de las principales conclusiones obtenidas, que permitirá identificar las limitaciones actuales y justificar la propuesta desarrollada en este trabajo.

2.1.CONTEXTO DEL PROBLEMA

El ajedrez ha sido, desde hace décadas, uno de los principales escenarios de estudio dentro del campo de la inteligencia artificial. Su combinación de reglas bien definidas y una enorme complejidad estratégica lo convierte en un entorno especialmente adecuado para analizar procesos de toma de decisiones en situaciones exigentes. Cada partida representa una secuencia de elecciones en las que intervienen tanto el conocimiento previo como la capacidad de adaptación del jugador.

A lo largo del tiempo, gran parte de la investigación se ha centrado en el desarrollo de motores de juego cada vez más potentes, capaces de alcanzar niveles de rendimiento superiores al humano. Estos avances han sido posibles gracias a técnicas como la búsqueda en árboles de decisión o, más recientemente, el uso de modelos de aprendizaje profundo. Sin embargo, este enfoque ha puesto el foco principalmente en encontrar la mejor jugada posible, dejando en un segundo plano el estudio del comportamiento individual de los jugadores.

En este punto es donde cobra importancia el concepto de estilo de juego. Más allá de la calidad objetiva de las jugadas, cada jugador presenta una forma característica de enfrentarse a la partida, que se refleja en sus decisiones. Algunos jugadores tienden a adoptar un enfoque más agresivo, buscando complicaciones tácticas, mientras que otros prefieren posiciones más estables y estratégicas. Estas diferencias no solo hacen el juego más rico, sino que también permiten analizar patrones de comportamiento que van más allá del resultado de una partida concreta.

Sin embargo, modelar este tipo de comportamiento no es una tarea sencilla. El estilo de juego no es una variable directamente observable, sino que debe inferirse a partir de múltiples partidas y decisiones. Además, no se trata de algo fijo: los jugadores evolucionan con el tiempo, cambian su forma de jugar, se adaptan a distintos rivales y mejoran con la experiencia. Esta naturaleza dinámica introduce una complejidad adicional que muchos enfoques tradicionales no logran capturar completamente.

Habitualmente, los métodos utilizados para analizar el estilo de juego se basan en características estáticas extraídas de partidas, lo que permite obtener una fotografía general del comportamiento de un jugador, pero no refleja cómo este evoluciona a lo largo del tiempo.

Como consecuencia, se pierde una parte importante de la información relacionada con la progresión y adaptación del jugador.

En este contexto, surge la necesidad de explorar nuevas formas de modelar el comportamiento en ajedrez que tengan en cuenta tanto las relaciones entre elementos del juego como su evolución temporal. En este trabajo se propone abordar este problema mediante una comparativa progresiva de representaciones, desde modelos tabulares clásicos hasta aproximaciones temporales y basadas en grafos, con el objetivo de analizar qué tipo de información resulta más útil para caracterizar estilos de juego.

2.2. ESTADO DEL ARTE

2.2.1. Aprendizaje autónomo en ajedrez mediante aprendizaje por refuerzo profundo

En el trabajo de DeepMind (2017), titulado *Mastering Chess and Shogi by Self-Play with a General Reinforcement Learning Algorithm*, se plantea como objetivo principal demostrar que un sistema de inteligencia artificial puede aprender a jugar al ajedrez desde cero, sin necesidad de incorporar conocimiento previo procedente de expertos humanos. Los autores proponen un enfoque basado en aprendizaje por refuerzo profundo, en el que el modelo adquiere conocimiento únicamente a partir de la experiencia generada mediante partidas contra sí mismo.

Más allá de este objetivo principal, el estudio también busca comprobar si este tipo de aprendizaje es capaz de alcanzar, e incluso superar, el rendimiento de los motores de ajedrez tradicionales, los cuales han sido desarrollados durante años a partir de heurísticas diseñadas manualmente y grandes bases de datos de partidas. En este sentido, el trabajo no solo pretende mejorar el rendimiento en el juego, sino también cuestionar el enfoque clásico basado en conocimiento experto.

El artículo explora además la capacidad de estos sistemas para desarrollar patrones de juego propios, lo que abre la puerta al análisis de estilos emergentes generados por la propia inteligencia artificial. Este aspecto resulta especialmente relevante en el contexto del presente trabajo, ya que sugiere que los modelos pueden no solo optimizar decisiones, sino también generar comportamientos característicos que podrían ser analizados desde la perspectiva del estilo de juego.

Para abordar el problema del aprendizaje del ajedrez desde cero, el enfoque propuesto se basa en la combinación de aprendizaje por refuerzo profundo (Deep Reinforcement Learning) y autojuego (self-play), eliminando la necesidad de conocimiento previo humano. El sistema parte únicamente de las reglas del juego y construye su estrategia a partir de la experiencia generada durante el entrenamiento.

El núcleo del modelo está constituido por una red neuronal profunda que integra dos componentes fundamentales: una función de política (policy network), que proporciona una distribución de probabilidad sobre los movimientos posibles en una posición dada, y una función de valor (value network), que estima la probabilidad de victoria desde dicha posición.

Ambas funciones se entrenan conjuntamente, permitiendo al modelo evaluar posiciones y seleccionar movimientos de forma eficiente.

La representación del estado del tablero se codifica como un conjunto de planos que describen la configuración de las piezas y otros elementos relevantes del juego, lo que permite a la red neuronal procesar la información de forma estructurada. A partir de esta representación, el modelo genera tanto la política de movimientos como la evaluación de la posición.

Para la toma de decisiones durante las partidas, el sistema combina las estimaciones de la red neuronal con un algoritmo de búsqueda basado en Monte Carlo Tree Search (MCTS). Este algoritmo permite explorar el espacio de posibles jugadas de manera selectiva, priorizando aquellas que presentan mayor probabilidad según la política y el valor estimados. La integración de MCTS con la red neuronal permite equilibrar exploración y explotación, mejorando la calidad de las decisiones.

El proceso de entrenamiento se realiza de forma iterativa mediante autojuego. En cada iteración, el sistema genera nuevas partidas utilizando la versión actual del modelo, y los datos obtenidos se emplean para actualizar los parámetros de la red neuronal. Este proceso sigue un esquema de mejora de políticas (policy iteration), en el que cada nueva versión del modelo es entrenada para imitar y superar el rendimiento de la anterior.

La optimización de la red se lleva a cabo mediante técnicas de descenso por gradiente, minimizando una función de pérdida que combina el error en la predicción del resultado de la partida (función de valor) y la divergencia entre la política predicha y la obtenida a partir de MCTS. De este modo, el modelo ajusta sus parámetros para mejorar tanto la selección de movimientos como la evaluación de posiciones.

Los resultados obtenidos muestran que el enfoque propuesto es altamente eficaz, logrando alcanzar un nivel de juego superior al de los motores tradicionales en un tiempo de entrenamiento relativamente reducido. En particular, el sistema es capaz de superar a Stockfish, uno de los motores de ajedrez más avanzados basados en búsqueda y conocimiento experto, tras solo unas horas de autoaprendizaje.

Este resultado demuestra la capacidad del modelo para aprender estrategias complejas a partir de la experiencia, sin necesidad de incorporar información previa procedente de

partidas humanas o reglas heurísticas diseñadas manualmente. Además, el rendimiento alcanzado no solo es competitivo, sino que representa un cambio significativo en la forma de abordar el problema del juego en ajedrez desde la inteligencia artificial.

Uno de los aspectos más relevantes del trabajo es la aparición de patrones de juego que difieren de los observados en los motores tradicionales. El sistema desarrolla un estilo de juego caracterizado por una mayor iniciativa, sacrificios posicionales y una preferencia por la actividad de piezas, lo que ha sido interpretado como un enfoque más creativo y dinámico.

Estos comportamientos sugieren que el modelo no se limita a reproducir estrategias conocidas, sino que es capaz de generar nuevas formas de juego a partir de su proceso de aprendizaje autónomo. Este aspecto resulta especialmente interesante en el contexto del presente trabajo, ya que refuerza la idea de que los sistemas de inteligencia artificial pueden desarrollar estilos propios, susceptibles de ser analizados y modelados.

2.2.2. Clasificación de estilos de juego en ajedrez mediante técnicas de aprendizaje automático

En contraste con los enfoques centrados en el rendimiento óptimo del juego, algunos trabajos han abordado el análisis del ajedrez desde una perspectiva más orientada al comportamiento de los jugadores. En este contexto, el estudio del estilo de juego se plantea como una forma de caracterizar las decisiones de un jugador más allá de la calidad objetiva de sus movimientos.

En esta línea, el trabajo de Levene et al. (2009) propone una metodología para aprender el estilo de juego de un jugador a partir de registros de partidas, con el objetivo de capturar patrones característicos de su forma de jugar. A diferencia de otros enfoques basados en la clasificación directa mediante características predefinidas, este trabajo se centra en modelar el estilo como una función implícita que refleja las preferencias del jugador a lo largo de la partida.

El objetivo principal del estudio es, por tanto, desarrollar un modelo capaz de aproximar la función de evaluación utilizada por un jugador durante la toma de decisiones, permitiendo así inferir su estilo de juego a partir de su comportamiento observable en partidas reales.

Para abordar el problema del aprendizaje del estilo de juego, Levene et al. (2009) proponen un enfoque basado en la estimación de funciones de evaluación personalizadas a partir de registros de partidas. El modelo asume que el comportamiento de un jugador puede aproximarse mediante una función de evaluación lineal, similar a las utilizadas en motores clásicos de ajedrez, pero cuyos parámetros se ajustan automáticamente a partir de datos.

La representación de cada posición del tablero se realiza mediante un conjunto de características (features) extraídas de funciones de evaluación tradicionales, incluyendo aspectos como la estructura de peones, la actividad y coordinación de las piezas, el control del centro y la seguridad del rey. Estas características se combinan linealmente mediante un vector de pesos que define la función de evaluación específica de cada jugador.

El proceso de aprendizaje de estos pesos se lleva a cabo utilizando técnicas de aprendizaje por diferencias temporales (Temporal Difference Learning, TD), en particular variantes del algoritmo TD(λ). Este tipo de aprendizaje permite ajustar los parámetros del modelo a partir de secuencias de estados observados en partidas reales, minimizando el error entre las evaluaciones sucesivas de posiciones consecutivas.

El modelo trata de aproximar una función de valor $V(s)$ que estima la calidad de una posición s , y cuyos parámetros se actualizan iterativamente siguiendo una regla de aprendizaje basada en el error temporal (temporal difference error). Este error se calcula como la diferencia entre la evaluación actual de una posición y la evaluación de la siguiente posición observada en la partida, permitiendo así propagar información a lo largo de la secuencia de jugadas.

El entrenamiento se realiza de manera individual para cada jugador, utilizando conjuntos de partidas históricas que permiten ajustar los parámetros del modelo a sus preferencias específicas. De este modo, el resultado final es una función de evaluación personalizada que refleja el estilo de juego del jugador en términos de cómo valora distintos aspectos del tablero.

Este enfoque presenta la ventaja de combinar técnicas clásicas del dominio del ajedrez con métodos de aprendizaje automático, permitiendo modelar el comportamiento del jugador de forma interpretable. Sin embargo, la dependencia de una representación lineal y de características predefinidas limita su capacidad para capturar relaciones más complejas entre variables.

Los resultados obtenidos por Levene et al. (2009) muestran que el enfoque basado en aprendizaje por diferencias temporales es capaz de aproximar de forma consistente la función de evaluación de distintos jugadores a partir de sus partidas. El modelo logra ajustar los pesos asociados a las distintas características del tablero de manera que reflejan las preferencias estratégicas individuales, permitiendo diferenciar entre estilos de juego.

Desde un punto de vista cuantitativo, el aprendizaje mediante $TD(\lambda)$ converge hacia funciones de evaluación estables que reproducen, en cierta medida, las decisiones observadas en las partidas originales. Esto indica que el modelo es capaz de capturar regularidades en la forma en que los jugadores valoran las posiciones, lo que constituye una aproximación efectiva al concepto de estilo de juego.

Además, el enfoque permite interpretar directamente los resultados, ya que los pesos aprendidos para cada característica ofrecen información sobre la importancia relativa que un jugador otorga a distintos aspectos del juego, como la estructura de peones, la actividad de las piezas o el control posicional. Esta interpretabilidad constituye una de las principales ventajas del modelo frente a otros enfoques más complejos.

Los resultados también presentan varias limitaciones. En primer lugar, la calidad del modelo depende en gran medida del conjunto de características utilizado, lo que implica que la capacidad de representación está condicionada por el conocimiento experto incorporado en dichas variables. En segundo lugar, el uso de una función de evaluación lineal restringe la capacidad del modelo para capturar interacciones no lineales entre características.

Por último, el enfoque no incorpora de forma explícita la dimensión temporal del comportamiento, ya que aprende una función de evaluación estática a partir de partidas históricas. Como consecuencia, aunque el modelo es capaz de diferenciar estilos entre jugadores, no permite analizar cómo estos evolucionan a lo largo del tiempo ni cómo se adaptan a distintos contextos de juego.

2.2.3. Predicción de movimientos humanos en ajedrez mediante aprendizaje automático

En los últimos años, ha surgido una línea de investigación centrada en el desarrollo de modelos capaces de predecir el comportamiento de jugadores humanos en ajedrez, con el objetivo de aproximarse no solo a la jugada óptima, sino a la decisión que un jugador real tomaría en una situación concreta. En este contexto, el trabajo de McIlroy-Young et al. (2020) propone un enfoque orientado a alinear modelos de inteligencia artificial con el comportamiento humano, utilizando el ajedrez como sistema de estudio.

El objetivo principal de este trabajo es desarrollar modelos capaces de predecir los movimientos realizados por jugadores humanos a partir de posiciones del tablero, capturando patrones de decisión asociados a distintos niveles de habilidad. A diferencia de los motores tradicionales, que buscan maximizar la probabilidad de victoria, este enfoque pretende modelar decisiones realistas, incluyendo errores y preferencias estratégicas.

Este planteamiento resulta especialmente relevante, ya que permite analizar el comportamiento humano de forma más precisa, proporcionando una base sólida para el estudio del estilo de juego desde una perspectiva dinámica.

El enfoque propuesto se basa en el uso de redes neuronales profundas inspiradas en la arquitectura de AlphaZero, adaptadas para predecir movimientos humanos en lugar de jugadas óptimas. En concreto, los autores desarrollan una familia de modelos denominada Maia, en la que cada instancia está entrenada para replicar el comportamiento de jugadores de un rango específico de nivel (ELO).

La representación del estado del tablero sigue un esquema similar al utilizado en AlphaZero, codificando la posición mediante tensores que describen la configuración de las piezas. A partir de esta entrada, la red neuronal genera una distribución de probabilidad sobre los posibles movimientos, interpretada como la probabilidad de que un jugador humano seleccione cada uno de ellos.

El entrenamiento se realiza utilizando aprendizaje supervisado sobre grandes bases de datos de partidas humanas, procedentes de plataformas como Lichess. Cada modelo se entrena para minimizar la divergencia entre las predicciones generadas y los movimientos reales observados, utilizando técnicas de optimización basadas en descenso por gradiente.

Una de las características más relevantes del enfoque es la segmentación por nivel de habilidad, lo que permite capturar diferencias en el comportamiento entre jugadores principiantes, intermedios y avanzados. De este modo, el modelo no solo aprende a predecir movimientos, sino también a reflejar cómo varía la toma de decisiones en función del nivel del jugador.

Los resultados obtenidos muestran que los modelos Maia son capaces de predecir movimientos humanos con una precisión superior a la de motores tradicionales optimizados para jugar de forma óptima. Se observa que estos modelos capturan de manera efectiva patrones de decisión asociados a distintos niveles de habilidad, reproduciendo tanto aciertos como errores característicos de los jugadores humanos.

Además, los resultados evidencian que los modelos especializados por nivel de ELO ofrecen un mejor rendimiento que los modelos generalistas, lo que confirma la importancia de considerar la heterogeneidad del comportamiento humano en este tipo de tareas.

El enfoque presenta ciertas limitaciones. Aunque permite modelar decisiones individuales con alta precisión, el análisis se realiza principalmente a nivel de posiciones aisladas, sin incorporar de manera explícita la evolución temporal del comportamiento a lo largo de múltiples partidas.

Este trabajo supone un avance en el modelado del comportamiento humano en ajedrez, pero es necesario enfoques que integren la dimensión temporal y estructural del juego, aspecto que resulta clave en el presente trabajo.

2.2.4. Modelado de grafos temporales dinámicos mediante redes neuronales

En los apartados anteriores se han revisado distintas aproximaciones para el análisis del comportamiento en ajedrez, incluyendo modelos centrados en el rendimiento óptimo, la clasificación de estilos de juego y la predicción de decisiones humanas. Sin embargo, todos estos enfoques comparten una limitación común: la dificultad para capturar de manera explícita la evolución del comportamiento a lo largo del tiempo.

Los grafos temporales dinámicos han surgido como una herramienta prometedora para modelar sistemas en los que las relaciones entre entidades cambian de forma continua. El trabajo de Rossi et al. (2020) introduce las Temporal Graph Networks (TGN), un marco general para el aprendizaje sobre grafos dinámicos mediante técnicas de aprendizaje profundo.

El objetivo principal de este trabajo es desarrollar una arquitectura capaz de modelar interacciones que evolucionan en el tiempo, permitiendo capturar tanto la estructura de las relaciones como su dinámica temporal. Este tipo de enfoque resulta especialmente relevante para problemas en los que las dependencias entre eventos no pueden representarse de forma estática.

El modelo propuesto se basa en la representación de los datos como un grafo dinámico, en el que los nodos representan entidades y las aristas representan interacciones que ocurren en instantes concretos del tiempo. A diferencia de los grafos estáticos, en este caso las conexiones no son fijas, sino que evolucionan a medida que se producen nuevos eventos.

La arquitectura de Temporal Graph Networks se compone de varios módulos principales. En primer lugar, cada nodo dispone de una memoria (node memory) que almacena información histórica sobre sus interacciones pasadas. Esta memoria se actualiza de forma continua a medida que se observan nuevos eventos, permitiendo al modelo mantener un contexto temporal.

En segundo lugar, el modelo incorpora funciones de actualización de memoria (memory updater), que utilizan mecanismos recurrentes, como redes neuronales recurrentes (RNN) o variantes tipo GRU, para integrar la información temporal. Estas funciones permiten capturar dependencias a lo largo del tiempo, lo que resulta clave en entornos dinámicos.

Además, el modelo incluye un mecanismo de agregación de mensajes (message passing), mediante el cual la información se propaga entre nodos a través de sus interacciones. Este

proceso permite combinar información estructural del grafo con información temporal, generando representaciones más completas.

A partir de estas representaciones, el modelo aprende embeddings dinámicos de los nodos, que evolucionan con el tiempo y reflejan tanto su posición en la estructura del grafo como su historial de interacciones. Estos embeddings pueden utilizarse posteriormente para tareas como predicción de enlaces, clasificación o modelado de comportamiento.

El entrenamiento del modelo se realiza mediante técnicas de aprendizaje supervisado o auto-supervisado, optimizando funciones de pérdida específicas en función de la tarea. Este enfoque permite aplicar el modelo a distintos dominios en los que las relaciones cambian de forma continua.

Los resultados presentados en el trabajo muestran que las Temporal Graph Networks superan a modelos basados en grafos estáticos y a otros enfoques dinámicos en tareas como la predicción de enlaces y el modelado de interacciones temporales. En particular, el uso de memoria y mecanismos de actualización temporal permite capturar dependencias complejas que no pueden ser representadas mediante enfoques tradicionales.

Además, el modelo demuestra una gran flexibilidad, siendo capaz de adaptarse a distintos tipos de datos y tareas, lo que lo convierte en una herramienta general para el análisis de sistemas dinámicos.

El trabajo se centra principalmente en dominios como redes sociales o sistemas de recomendación, sin explorar directamente su aplicación al ámbito del ajedrez. Existe una oportunidad de investigación, ya que las características del ajedrez (particularmente la secuencia de decisiones y la evolución del comportamiento) encajan de manera natural con este tipo de modelos.

Explorar representaciones basadas en grafos dinámicos para el análisis del estilo de juego en ajedrez puede considerarse una línea de trabajo interesante, ya que permite conectar la estructura del tablero con la evolución temporal de la partida.

2.2.5. Revisión de técnicas de aprendizaje en grafos dinámicos

Dado el creciente interés en el modelado de sistemas dinámicos mediante grafos, han surgido diversos trabajos orientados a revisar y clasificar las distintas técnicas existentes en este ámbito. En particular, el estudio de Kazemi et al. (2020) proporciona una visión general de los métodos de aprendizaje de representaciones en grafos dinámicos, analizando sus principales características, aplicaciones y limitaciones.

El objetivo principal de este tipo de trabajos es organizar el estado del arte en el campo de los grafos dinámicos, identificando las distintas aproximaciones existentes y proporcionando un marco conceptual que permita entender las diferencias entre ellas. Este análisis resulta fundamental para situar nuevas propuestas dentro del contexto de investigación actual.

Este tipo de revisión permite comprender mejor las distintas alternativas disponibles para modelar relaciones dinámicas, así como justificar la elección de enfoques específicos como las Temporal Graph Networks.

La revisión clasifica los métodos de aprendizaje en grafos dinámicos en función de distintos criterios, siendo uno de los principales la forma en que se modela la evolución temporal. En este sentido, los enfoques se dividen generalmente en dos grandes categorías: métodos basados en instantáneas (snapshot-based methods), que representan el grafo como una secuencia de estados discretos en el tiempo, y métodos basados en eventos (event-based methods), que modelan directamente las interacciones a medida que ocurren.

Dentro de estas categorías, se analizan distintos tipos de modelos, incluyendo extensiones de redes neuronales sobre grafos (Graph Neural Networks, GNN), modelos recurrentes como RNN o LSTM aplicados a secuencias de grafos, y enfoques más recientes que incorporan mecanismos de atención o memoria para capturar dependencias temporales.

La revisión también describe las distintas tareas asociadas a grafos dinámicos, como la predicción de enlaces (link prediction), la clasificación de nodos o el modelado de secuencias de eventos, así como los tipos de datos utilizados en estos problemas.

Además, se discuten aspectos clave como la representación de los nodos mediante embeddings dinámicos, que evolucionan con el tiempo, y los retos asociados al escalado de estos modelos en entornos con grandes volúmenes de datos.

El análisis realizado en la revisión concluye que los enfoques basados en grafos dinámicos ofrecen ventajas significativas frente a los modelos estáticos, especialmente en contextos donde las relaciones entre entidades cambian de forma continua. En particular, la capacidad de capturar la evolución temporal permite modelar fenómenos complejos que no pueden ser representados adecuadamente mediante grafos estáticos.

Asimismo, el estudio destaca la importancia de incorporar mecanismos de memoria y actualización temporal para capturar dependencias a largo plazo, aspecto que resulta clave en muchos dominios reales. En este sentido, modelos como las Temporal Graph Networks representan una evolución natural de estas ideas.

También identifica varios retos abiertos, incluyendo la complejidad computacional de estos modelos, la dificultad para interpretar las representaciones aprendidas y la falta de aplicaciones en ciertos dominios específicos.

Tabla 1. Principales enfoques para el aprendizaje en grafos dinámicos.

Tipo de enfoque	Descripción	Técnicas utilizadas	Ventajas	Limitaciones
Basado en snapshots	Representa el grafo como una secuencia de estados discretos	GNN + RNN / LSTM	Fácil de implementar	Pérdida de información temporal fina
Basado en eventos	Modela interacciones como eventos continuos en el tiempo	Temporal Graph Networks, atención temporal	Captura dinámica real	Mayor complejidad
Modelos con memoria	Incorporan estado histórico en los nodos	RNN, GRU, memoria explícita	Captura dependencias largas	Coste computacional
Embeddings dinámicos	Representaciones que evolucionan en el tiempo	Deep learning sobre grafos	Flexibilidad	Difícil interpretación

Fuente: elaboración propia.

Como se puede observar, los enfoques basados en eventos y mecanismos de memoria ofrecen una mayor capacidad para modelar la evolución temporal de las interacciones, lo que los convierte en una opción especialmente adecuada para problemas donde el comportamiento cambia a lo largo del tiempo.

2.2.6. Representación basada en grafos en ajedrez

Además de los enfoques basados en representaciones matriciales del tablero, en los últimos años han comenzado a explorarse aproximaciones basadas en grafos para modelar estados de juego en ajedrez. En esta línea, el trabajo de Rigaux y Kashima (2024), titulado *Enhancing Chess Reinforcement Learning with Graph Representation*, propone sustituir la representación tradicional basada en cuadrículas por una representación estructural mediante grafos.

El objetivo principal de este trabajo es mejorar la flexibilidad de los modelos inspirados en AlphaZero mediante el uso de Graph Neural Networks. Los autores señalan que las arquitecturas basadas en redes convolucionales presentan ciertas limitaciones cuando se aplican a juegos o variantes con estructuras diferentes, ya que suelen depender de una representación rígida del tablero. Frente a ello, los grafos permiten representar relaciones entre elementos del juego de una forma más flexible.

En la propuesta de Rigaux y Kashima, el estado del tablero se representa como un grafo en el que las casillas actúan como nodos y los movimientos posibles se modelan como aristas. Además, el modelo incorpora características tanto en los nodos como en las aristas, lo que permite describir información sobre la posición, la legalidad de los movimientos, la dirección de desplazamiento o posibles promociones.

A partir de esta representación, los autores desarrollan una arquitectura denominada AlphaGateau, basada en una variante de Graph Attention Network capaz de incorporar información de aristas. Esta arquitectura se integra dentro de un esquema de aprendizaje por refuerzo inspirado en AlphaZero, combinando redes neuronales, autojuego y búsqueda Monte Carlo Tree Search.

Los resultados experimentales muestran que la representación basada en grafos puede mejorar la eficiencia del aprendizaje frente a una arquitectura reducida de AlphaZero basada en redes convolucionales. En particular, los autores observan que AlphaGateau alcanza un mayor nivel de juego con un número comparable de parámetros y presenta cierta capacidad de generalización entre variantes de ajedrez de distinto tamaño.

Aunque este trabajo se centra en el entrenamiento de agentes de juego mediante aprendizaje por refuerzo, resulta especialmente relevante para el presente TFM porque demuestra que

las representaciones basadas en grafos pueden capturar información estructural del ajedrez de manera eficaz. No obstante, el objetivo del presente trabajo es diferente: no se busca entrenar un motor de juego, sino analizar estilos de jugadores humanos a partir de partidas reales.

Además, la representación utilizada en este TFM difiere de la propuesta por Rigaux y Kashima. Mientras que en AlphaGateau los nodos representan casillas y las aristas movimientos posibles, en este trabajo los nodos representan piezas y las aristas modelan relaciones de ataque y defensa entre ellas. Esta diferencia permite adaptar la representación en grafos al objetivo específico del análisis de estilos de juego.

2.3. MARCO TEORICO

2.3.1. Aprendizaje automático supervisado

En este trabajo se utiliza aprendizaje automático supervisado porque el problema se plantea como una tarea de clasificación. Cada partida se representa mediante un conjunto de características extraídas del PGN y se asocia a una etiqueta de estilo de juego. A partir de estos ejemplos, los modelos intentan aprender patrones que permitan diferenciar entre los estilos definidos.

Este enfoque permite evaluar de forma cuantitativa si las variables extraídas aportan información útil para clasificar partidas. En el caso de este TFM, las características incluyen datos generales de la partida, información del jugador, aperturas, métricas de actividad táctica y variables calculadas desde la perspectiva del jugador principal.

Es importante tener en cuenta que la etiqueta de estilo no aparece directamente en la partida. Se trata de una aproximación basada en el perfil histórico del jugador analizado. Por este motivo, el objetivo no es afirmar que el modelo reconoce el estilo de forma perfecta, sino comprobar qué representaciones ayudan más a encontrar diferencias entre grupos de partidas.

Se entrenan diferentes modelos supervisados y se comparan sus resultados mediante métricas de clasificación. Esta comparación sirve como base para estudiar después si las representaciones temporales y basadas en grafos aportan información adicional frente a las variables tabulares iniciales.

2.3.2. Modelos clásicos de clasificación

En la primera parte del trabajo se utilizan modelos clásicos de clasificación sobre datos tabulares. Con el fin de establecer una base inicial con modelos conocidos y relativamente fáciles de interpretar antes de probar representaciones más complejas.

Uno de los modelos considerados es la Regresión Logística. En este caso se utiliza como modelo de clasificación. Su funcionamiento se basa en estimar la probabilidad de que una muestra pertenezca a cada clase a partir de una combinación de las variables de entrada. Permite comprobar hasta qué punto las características extraídas separan los estilos de forma lineal.

También se emplea Random Forest, un modelo basado en la combinación de múltiples árboles de decisión. Cada árbol aprende reglas a partir de una parte de los datos y, después, el resultado final se obtiene combinando sus predicciones. Este modelo suele funcionar bien en problemas tabulares y permite capturar relaciones no lineales entre variables, algo interesante en este caso porque el estilo de juego puede depender de la combinación de varias características.

Por último, se utiliza XGBoost, un modelo basado en boosting que construye árboles de forma secuencial. A diferencia de Random Forest, donde los árboles se entrenan de forma más independiente, en XGBoost cada nuevo árbol intenta corregir parte de los errores cometidos por los anteriores. Esto puede mejorar el rendimiento, aunque también requiere controlar mejor sus hiperparámetros para evitar sobreajuste.

Estos tres modelos permiten comparar distintos niveles de complejidad sobre la misma representación inicial de las partidas. De esta manera, se puede analizar si las diferencias entre estilos aparecen ya en las variables tabulares o si es necesario incorporar información temporal o estructural.

2.3.3. Optimización de hiperparámetros

Los hiperparámetros son configuraciones que se fijan antes de entrenar un modelo y que pueden afectar de forma directa a su rendimiento. A diferencia de los parámetros internos, que el modelo aprende durante el entrenamiento, los hiperparámetros deben elegirse mediante pruebas o mediante un procedimiento de búsqueda.

En modelos como Random Forest, algunos hiperparámetros habituales son el número de árboles, la profundidad máxima o el número mínimo de muestras necesario para dividir un nodo. En XGBoost también son importantes la tasa de aprendizaje, el número de estimadores, la profundidad de los árboles y los porcentajes de muestreo. En Regresión Logística suele ajustarse el parámetro de regularización y, según el caso, el tipo de penalización utilizada.

Para seleccionar estos valores se pueden utilizar técnicas como Grid Search o Randomized Search. Grid Search evalúa todas las combinaciones definidas en un conjunto de valores, mientras que Randomized Search prueba solo una parte de ellas de forma aleatoria. La primera estrategia es más exhaustiva, pero puede requerir más tiempo de cómputo. La segunda permite explorar espacios de búsqueda más amplios con menor coste.

La optimización de hiperparámetros resulta especialmente importante cuando se comparan varios modelos, ya que una configuración poco adecuada puede empeorar los resultados y llevar a conclusiones poco fiables. Por ello, antes de comparar el rendimiento final de distintos enfoques, es conveniente definir un criterio común de selección y aplicar el mismo procedimiento de evaluación siempre que sea posible.

2.3.4. Métricas de evaluación

Para comparar modelos de clasificación es necesario utilizar métricas que permitan medir su rendimiento de forma objetiva. La métrica más básica es la accuracy, que indica el porcentaje total de predicciones correctas. Aunque es fácil de interpretar, puede no ser suficiente cuando las clases no están perfectamente equilibradas o cuando interesa saber cómo se comporta el modelo en cada categoría.

Por este motivo, también se utilizan métricas como precision, recall y F1-score. La precision mide cuántas de las predicciones realizadas para una clase son correctas, mientras que el recall indica cuántos ejemplos reales de esa clase han sido identificados correctamente. El F1-score combina ambas medidas y permite obtener una visión más equilibrada del rendimiento.

En problemas multiclase, como el planteado en este trabajo, estas métricas pueden calcularse para cada clase y después agregarse mediante diferentes promedios. En este caso resulta especialmente útil el F1-score macro, ya que calcula el rendimiento medio dando el mismo peso a todas las clases. Esto ayuda a evitar que el resultado global dependa demasiado de las clases con más partidas.

Además de estas métricas, la matriz de confusión permite analizar qué clases se clasifican correctamente y cuáles se confunden entre sí.

2.3.5. Grafos temporales dinámicos

Los grafos son una forma de representar información mediante nodos y aristas. Esta estructura resulta especialmente útil cuando el problema no depende solo de valores individuales, sino también de las relaciones entre distintos elementos. En ajedrez, una posición no está formada únicamente por piezas colocadas en casillas, sino por relaciones entre ellas: piezas que atacan, piezas que defienden, casillas controladas, amenazas posibles o estructuras que limitan el movimiento del rival.

Desde este punto de vista, una partida de ajedrez puede interpretarse como una secuencia de estados relacionados entre sí. Cada posición del tablero representa un momento concreto de la partida, y cada movimiento modifica la estructura anterior. Por tanto, si se representa una posición como un grafo, la partida completa puede entenderse como una sucesión de grafos que cambian con el tiempo. Esta idea es la base de los grafos temporales dinámicos.

En un grafo temporal dinámico, los nodos y las aristas pueden variar a lo largo del tiempo. Aplicado al ajedrez, esto significa que las relaciones entre piezas no son fijas: una pieza puede estar defendida en una posición, quedar atacada después de un movimiento o dejar de participar en la estructura si es capturada. Esta evolución permite representar no solo qué elementos aparecen en una posición, sino también cómo cambian sus relaciones durante el desarrollo de la partida.

Este tipo de representación puede aportar información que no aparece de forma clara en las variables tabulares tradicionales. Por ejemplo, dos partidas pueden tener un número parecido de capturas, jaques o movimientos, pero presentar estructuras muy diferentes. Una puede estar basada en presión constante sobre el rey rival, mientras que otra puede desarrollarse mediante acumulación de pequeñas ventajas posicionales. En una tabla de características agregadas, estas diferencias pueden quedar parcialmente ocultas.

La utilidad de los grafos en este trabajo está relacionada con la posibilidad de representar la estructura interna de una posición. En lugar de describir solo cuántas capturas o jaques se han producido, un grafo permite modelar qué piezas intervienen, cómo se conectan y qué tipo de relaciones se generan entre ellas. Esto resulta relevante para el análisis de estilos de juego, ya que ciertos perfiles pueden diferenciarse más por la forma de construir posiciones que por estadísticas generales de la partida.

Trabajar con grafos también introduce más complejidad. Es necesario decidir qué elementos serán los nodos, qué relaciones se considerarán aristas y en qué momentos de la partida se construirán los grafos. Además, cuanto más detallada sea la representación, mayor será el coste de procesamiento y más difícil puede resultar interpretar los resultados.

En este TFM, la representación basada en grafos se emplea para estudiar si la estructura de las posiciones aporta información adicional en la clasificación de estilos de juego, comparándola con enfoques más simples y analizando hasta qué punto permite capturar patrones que no aparecen claramente en las variables tabulares.

Representar el dato como una secuencia de grafos es solo el primer paso: queda por decidir qué modelo aprende de esa representación. Conviene, por ello, distinguir entre la representación del dato y el modelo de aprendizaje. Sobre un dato dinámico como el descrito caben dos estrategias: procesar cada grafo de forma independiente con una red neuronal sobre grafos y agregar después las predicciones a nivel de partida, o procesar la secuencia completa con un modelo capaz de capturar su evolución temporal.

Ambos componentes se describen a continuación y, combinados, dan lugar al modelo de grafos temporales dinámicos que se emplea en el apartado 4.

2.3.5.1. Redes neuronales sobre grafos: GNN/GCN

Una red neuronal sobre grafos, o GNN, es un modelo capaz de aprender directamente a partir de la estructura de un grafo, sin convertirlo previamente en una tabla de características. Su funcionamiento se basa en el paso de mensajes: cada nodo actualiza su representación combinando su propia información con la de los nodos vecinos a los que está conectado.

De este modo, al repetir este proceso en varias capas, la información se propaga por el grafo y cada nodo acaba codificando tanto sus propias características como su contexto estructural.

Para clasificar un grafo completo, como una posición de ajedrez, es necesario resumir las representaciones de todos los nodos en un único vector. Esto se realiza mediante una operación de agregación o pooling, por ejemplo, calculando la media de los vectores de todos los nodos. Sobre este vector agregado se aplica después una capa final de clasificación.

Una variante habitual es la red convolucional sobre grafos, o GCN, que define el paso de mensajes como una convolución adaptada a la estructura del grafo.

2.3.5.2. Modelos de secuencia: RNN/GRU

Cuando el dato no es un único elemento, sino una secuencia ordenada, como la sucesión de posiciones de una partida, resulta útil emplear modelos que la procesen teniendo en cuenta el orden. Las redes neuronales recurrentes, o RNN, están diseñadas para ello: mantienen un estado interno que se actualiza a medida que reciben cada elemento de la secuencia, de manera que la representación final resume toda la evolución observada.

Una de sus variantes más utilizadas es la GRU, o Gated Recurrent Unit, que incorpora mecanismos de puerta para controlar qué información se conserva y cuál se descarta en cada paso. Esto facilita aprender dependencias a lo largo de secuencias más largas.

En este trabajo, una GRU permite combinar las representaciones de los sucesivos grafos de una partida en una única predicción de estilo, aprovechando así la dimensión temporal del dato.

2.4.CONCLUSIONES

En este capítulo se han revisado distintas aproximaciones al estudio del ajedrez desde la inteligencia artificial. Por un lado, se han analizado trabajos orientados al rendimiento de juego, como los modelos basados en aprendizaje por refuerzo profundo. Estos enfoques han demostrado una gran capacidad para aprender estrategias complejas, aunque su objetivo principal no es estudiar el estilo de jugadores humanos, sino optimizar la toma de decisiones dentro del juego.

También se han revisado trabajos más cercanos al análisis del comportamiento, como los centrados en el aprendizaje de estilos de juego o en la predicción de movimientos humanos. Estos estudios resultan especialmente relevantes para este TFM, ya que muestran que es posible modelar ciertos patrones de decisión a partir de partidas reales. Aun así, varios de estos enfoques trabajan con representaciones estáticas o con posiciones aisladas, lo que limita el análisis de la evolución completa de una partida.

Por otro lado, se han considerado trabajos relacionados con grafos dinámicos y representaciones basadas en grafos aplicadas al ajedrez. Estas aproximaciones son interesantes porque permiten representar relaciones entre elementos del tablero y no solo variables generales de la partida. Sin embargo, su aplicación directa al análisis de estilos de juego todavía es limitada, por lo que existe margen para explorar este tipo de representación en este contexto.

A partir de esta revisión, se observa que el análisis del estilo ajedrecístico no depende únicamente de estadísticas agregadas, como capturas, jaques o duración de la partida. También puede ser importante considerar cómo evoluciona el juego y cómo se estructuran las relaciones entre piezas en distintos momentos. Por este motivo, el presente trabajo plantea una comparativa, en igualdad de condiciones, entre modelos clásicos, representaciones temporales por fases y una representación estructural basada en grafos de posiciones.

El marco teórico presentado permite situar las técnicas que se emplearán en el desarrollo experimental. Entre ellas se incluyen el aprendizaje supervisado, los modelos clásicos de clasificación, la optimización de hiperparámetros, las métricas de evaluación, los grafos

Aprendizaje de estilos de juego en ajedrez mediante modelos de Machine Learning y grafos temporales dinámicos
temporales dinámicos, las redes neuronales sobre grafos (GNN/GCN) y los modelos de secuencia (GRU).

3. OBJETIVOS CONCRETOS Y METODOLOGÍA DE TRABAJO

3.1.OBJETIVO GENERAL

El objetivo general de este trabajo es desarrollar una comparativa de soluciones de inteligencia artificial para el análisis de estilos de juego en ajedrez. Evaluando en igualdad de condiciones distintos enfoques: modelos clásicos de aprendizaje automático, una representación temporal basada en fases de juego y una representación estructural basada en grafos de posiciones.

Los datos se obtienen a partir de partidas reales en formato PGN, utilizando las mismas particiones de entrenamiento y prueba para todos los modelos. Con ello se busca analizar en qué medida cada tipo de representación permite identificar patrones asociados a distintos perfiles de juego.

En la comparación se utilizan métricas de clasificación como accuracy, precision, recall y F1-score, junto con el análisis de matrices de confusión. Dado el desbalanceo moderado entre clases, se adopta el F1-macro como criterio de referencia, ya que pondera por igual las cuatro clases.

La idea no es obtener una detección perfecta del estilo de juego, sino estudiar qué información resulta más útil y qué limitaciones aparecen al aplicar estas técnicas al análisis de partidas de ajedrez.

3.2.OBJETIVOS ESPECÍFICOS

Para alcanzar el objetivo general planteado, se definen los siguientes objetivos específicos:

- Construir un conjunto de datos de partidas históricas en formato PGN, asociado a jugadores con perfiles de estilo diferenciados, y extraer de él tres representaciones complementarias: métricas agregadas, variables por fases de juego y grafos de posiciones basados en las relaciones de ataque y defensa entre piezas.
- Implementar y optimizar modelos clásicos de clasificación (regresión logística, Random Forest y XGBoost) sobre las representaciones tabulares, tanto agregadas como por fases.
- Diseñar y evaluar arquitecturas de redes neuronales sobre grafos —una red convolucional (GCN) con agregación a nivel de partida y un modelo temporal que combina la GCN con una red recurrente (GRU)— y compararlas con los modelos clásicos en igualdad de condiciones, utilizando métricas como accuracy, precision, recall, F1-score y matrices de confusión.
- Analizar las ventajas y limitaciones de las representaciones tabulares, temporales y estructurales utilizadas en el trabajo.

3.3.METODOLOGÍA DEL TRABAJO

La metodología seguida en este trabajo se organizó en varias fases, desde la preparación de los datos hasta la evaluación de los modelos. El objetivo fue comparar distintas formas de representar una partida de ajedrez y analizar si esas representaciones ayudan a diferenciar estilos de juego.

En primer lugar, se recopilaron partidas históricas en formato PGN procedentes de repositorios públicos especializados, principalmente PGN Mentor. La selección se centró en jugadores con perfiles de estilo reconocibles, como enfoques tácticos, posicionales, dinámicos y defensivos. Esta selección permitió construir un conjunto de datos inicial orientado al análisis comparativo de estilos.

Después, se realizó un proceso de limpieza y filtrado de las partidas. Se eliminaron partidas demasiado cortas o con problemas de formato, y se normalizaron distintos campos del PGN para facilitar su tratamiento posterior. También se adaptaron las variables desde la perspectiva del jugador principal, ya que un mismo jugador puede aparecer con piezas blancas o negras.

A continuación, se extrajeron características de cada partida. Entre ellas se incluyeron variables generales como duración, resultado, capturas, jaques, enroques, promociones e información de apertura. Estas características permitieron construir una primera representación tabular de las partidas.

Sobre esta representación inicial se entrenaron modelos clásicos de clasificación, como Regresión Logística, Random Forest y XGBoost. Además, se incorporó una fase de optimización de hiperparámetros mediante técnicas de búsqueda, con el objetivo de evitar comparar modelos a partir de configuraciones elegidas de forma arbitraria.

La evaluación se realizó mediante métricas como *accuracy*, *precision*, *recall* y *F1-score*, prestando especial atención al *F1-score macro* y a las matrices de confusión.

Posteriormente, se construyó una representación temporal basada en la división de las partidas en fases de juego. Esta aproximación permitió calcular características diferenciadas para distintos momentos de la partida y comprobar si esta información aportaba alguna mejora respecto a las variables agregadas.

Finalmente, se exploró una representación basada en grafos de posiciones. Cada partida se modeló como una secuencia de grafos, es decir, un grafo por posición. En estos grafos, las piezas se representaron como nodos y las relaciones de ataque y defensa como aristas.

Sobre esta representación se evaluaron dos arquitecturas. La primera fue una red convolucional sobre grafos (GCN), encargada de clasificar cada posición y agregar sus predicciones a nivel de partida. La segunda fue un modelo temporal que procesa la secuencia de posiciones mediante una red recurrente GRU.

En ambos casos, la unidad de predicción es la partida, igual que en los modelos clásicos, y sus hiperparámetros se ajustaron mediante búsqueda. Para que la comparación entre todas las familias de modelos fuera rigurosa, todos los enfoques se evaluaron sobre las mismas particiones de entrenamiento y prueba. Además, como el entrenamiento de las redes neuronales no es determinista, sus resultados se promediaron sobre varias semillas.

Una vez obtenidos los resultados, se compararon los distintos enfoques atendiendo tanto a sus métricas como a sus limitaciones. Esta comparación permitió valorar qué representaciones resultaron más útiles en el contexto del trabajo y qué aspectos deberían mejorarse en futuras ampliaciones.

4. DESARROLLO ESPECÍFICO DE LA CONTRIBUCIÓN

La primera fase consiste en desarrollar un proceso completo de recopilación, limpieza y transformación de datos, así como diferentes representaciones de las partidas orientadas a los modelos estudiados en este trabajo.

A diferencia de otros problemas clásicos de clasificación, el análisis de estilos de juego presenta una dificultad adicional relacionada con la naturaleza secuencial y estratégica del ajedrez. El comportamiento de un jugador no depende únicamente de posiciones aisladas, sino también de la evolución de la partida, las decisiones tomadas en distintos momentos y la interacción entre múltiples elementos del tablero. Por este motivo, el desarrollo experimental se ha diseñado buscando representar tanto características estáticas como relaciones temporales y estructurales dentro de las partidas.

El proceso desarrollado comienza con la recopilación de partidas históricas en formato PGN procedentes de repositorios especializados. Posteriormente, se realiza una fase de preprocesamiento orientada a limpiar y normalizar la información contenida en los archivos, permitiendo construir conjuntos de datos consistentes para el entrenamiento de modelos de aprendizaje automático.

A partir de estos datos se generan diferentes representaciones de las partidas, incluyendo variables tabulares tradicionales, secuencias temporales y estructuras basadas en grafos dinámicos. Sobre dichas representaciones se implementarán posteriormente distintos modelos de aprendizaje con el objetivo de estudiar su capacidad para capturar patrones asociados al estilo de juego de distintos jugadores.

En las siguientes secciones se detallan las distintas fases del desarrollo experimental, incluyendo la construcción del conjunto de datos, el proceso de extracción de características, las representaciones utilizadas y la implementación de los modelos empleados en la comparativa.

4.1.CONSTRUCCIÓN DEL CONJUNTO DE DATOS

El conjunto de datos empleado en este trabajo se compone de partidas de torneo de cuatro jugadores de élite, seleccionados por estar asociados de forma reconocible a un estilo de juego de referencia: Anatoli Karpov, vinculado a un estilo posicional; Mijaíl Tal, de carácter táctico; Garri Kaspárov, de estilo dinámico; y Tigran Petrosián, de orientación defensiva.

Las partidas, obtenidas en formato PGN, abarcan el periodo comprendido entre 1945 y 2022. Su distribución por jugador y estilo se recoge en la Tabla 2.

Tabla 2. Distribución de partidas por jugador y estilo.

Jugador	Estilo	Partidas
Karpov	Posicional	3.519
Tal	Táctico	2.417
Kaspárov	Dinámico	2.123
Petrosián	Defensivo	1.877
Total		9.936

Fuente: elaboración propia a partir de PGN Mentor (s. f.).

Dado que cada jugador aporta partidas de un único estilo, la etiqueta de estilo coincide en la práctica con la identidad del jugador. Esta circunstancia condiciona la interpretación de los resultados y motiva el experimento de generalización entre jugadores que se describe en el apartado 4.8.

Asimismo, las clases presentan un desbalanceo moderado, con valores comprendidos entre 1.877 y 3.519 partidas. Por este motivo, durante el entrenamiento se emplearon pesos de clase y se adoptó el *F1-macro* como métrica principal de comparación.

4.2. PREPROCESAMIENTO Y EXTRACCIÓN DE CARACTERÍSTICAS

A partir de cada partida en formato PGN se construyeron tres representaciones complementarias, orientadas a capturar aspectos distintos del juego.

La primera representación resume cada partida mediante seis variables numéricas: número de movimientos, capturas del jugador, jaques del jugador, tasa de capturas, tasa de jaques y puntuación de agresividad. Además, se incorpora la familia de apertura codificada según el sistema ECO.

La segunda representación incorpora la dimensión temporal. Para ello, desagrega distintas magnitudes en las tres fases canónicas de la partida: apertura, medio juego y final. En concreto, se consideran capturas, jaques, enroques y promociones, tanto del jugador como del rival. Esta representación da lugar a veintiuna variables de fase.

La tercera representación, de naturaleza estructural, transforma cada partida en una secuencia de grafos de posición. En este caso, cada grafo representa una posición concreta del tablero, y su construcción se detalla en el apartado 4.7.

4.3. ANÁLISIS EXPLORATORIO DEL CONJUNTO DE DATOS

En el análisis exploratorio se pueden ver señales asociadas al estilo son débiles y se solapan entre clases. La Tabla 3 muestra los valores medios de tres indicadores de actividad para cada uno de los estilos considerados.

Tabla 3. Valores medios de los indicadores de actividad por estilo.

Estilo	<i>aggression_score</i>	<i>capture_rate</i>	<i>check_rate</i>
Dinámico	0,267	0,218	0,049
Táctico	0,263	0,218	0,046
Posicional	0,242	0,206	0,037
Defensivo	0,223	0,195	0,028

Fuente: elaboración propia.

Aunque el orden resultante es coherente con la intuición ajedrecística, ya que los estilos dinámico y táctico exhiben una actividad algo mayor que el posicional y el defensivo, las diferencias absolutas entre clases son reducidas. Conviene señalar, además, que la puntuación de agresividad se define como la suma de las tasas de captura y de jaque. Por tanto, resulta colineal respecto a ellas y aporta información redundante a los modelos lineales. Se mantiene en el análisis por su valor interpretativo.

4.4.DISEÑO EXPERIMENTAL

Con el fin de garantizar una comparación rigurosa entre las distintas familias de modelos, el protocolo experimental se definió de manera común a todas ellas. Como criterio de selección y comparación se adoptó el *F1-macro*, por las razones expuestas en el apartado 2.3.

La reproducibilidad de los experimentos se aseguró fijando una misma semilla aleatoria en todas las particiones, búsquedas y modelos, y empleando particiones estratificadas por estilo. En el caso de los modelos clásicos, el preprocesado se integró en un único *pipeline*. Este preprocesado incluyó la estandarización de las variables numéricas y la codificación *one-hot* de la familia de apertura, de modo que las transformaciones se ajustaran exclusivamente sobre los datos de entrenamiento y se evitara cualquier fuga de información hacia el conjunto de prueba.

Las particiones se adaptaron a las necesidades de cada familia de modelos. Los modelos clásicos se evaluaron mediante una división estratificada en proporción 80/20, con 7.948 partidas de entrenamiento y 1.988 de prueba. Sobre esta partición se aplicó una validación cruzada estratificada de cinco particiones y un reentrenamiento final optimizado sobre el *F1-macro*.

Los modelos basados en grafos, en cambio, requieren un conjunto de validación independiente para aplicar parada temprana y seleccionar la arquitectura. Por este motivo, se recurrió a una división 60/20/20, con 5.985 partidas de entrenamiento, 1.996 de validación y 1.996 de prueba, respectivamente.

En este último caso, la partición se realizó por partida y no por posición. El objetivo fue evitar que distintas posiciones de una misma partida quedaran repartidas entre los conjuntos de entrenamiento y prueba, lo que constituiría una fuente de fuga de información.

Los resultados presentados en los apartados 4.5 a 4.7 corresponden a estas particiones de búsqueda de hiperparámetros y no son, en consecuencia, directamente comparables entre familias. La comparación en condiciones equivalentes se aborda de forma específica en el apartado 4.9.

La búsqueda de hiperparámetros se ajustó al método más apropiado para cada familia de modelos. Para la regresión logística se empleó una búsqueda exhaustiva en rejilla. Para Random Forest y XGBoost se combinó la búsqueda en rejilla con una búsqueda aleatoria, dado

su mayor número de hiperparámetros relevantes. Para los modelos de grafos se utilizó una búsqueda aleatoria con parada temprana guiada por el *F1-macro* de validación.

Por último, la comparación final entre familias, presentada en el apartado 4.9, se llevó a cabo en condiciones estrictamente equivalentes. Todos los modelos, tanto clásicos como basados en grafos, se entrenaron sobre exactamente las mismas partidas y se evaluaron sobre un mismo conjunto de prueba de 1.965 partidas, obtenido al emparejar ambas representaciones mediante una clave común.

De este modo, todos los enfoques comparten la misma tarea, compuesta por cuatro clases; la misma unidad de predicción, una etiqueta por partida; y la misma métrica principal. Por tanto, las diferencias observadas no pueden atribuirse a particiones distintas.

Puesto que la inicialización de las redes neuronales es aleatoria, los modelos de grafos se promediaron sobre cinco semillas y se reportan como media y desviación típica. En cambio, los modelos clásicos, de carácter determinista, se reportan con un único valor.

4.5. MODELOS CLÁSICOS CON CARACTERÍSTICAS AGREGADAS

El primero de los modelos clásicos considerados es la regresión logística, con regularización L2 y pesos de clase balanceados. La búsqueda en rejilla seleccionó la configuración recogida en la Tabla 4.

Tabla 4. Hiperparámetros seleccionados para la regresión logística.

Hiperparámetro	Valor seleccionado
C	0,01
class_weight	Balanced

Fuente: elaboración propia.

Sobre el conjunto de prueba, el modelo alcanzó una exactitud de 0,380 y un *F1-macro* de 0,366. Su comportamiento por clases resultó desigual: las clases posicional y táctica fueron las mejor reconocidas, con valores de F1 de 0,435 y 0,425, respectivamente. En cambio, la clase dinámica se reveló como la más problemática, con un F1 de 0,247.

El segundo modelo, Random Forest, se ajustó mediante búsqueda aleatoria. La configuración seleccionada se muestra en la Tabla 5.

Tabla 5. Hiperparámetros seleccionados para Random Forest (características agregadas).

Hiperparámetro	Valor seleccionado
n_estimators	600
max_depth	6
max_features	log2
min_samples_split	2
min_samples_leaf	2
class_weight	balanced

Fuente: elaboración propia.

Este modelo obtuvo en prueba una exactitud de 0,366 y un *F1-macro* de 0,357, valores ligeramente inferiores a los de la regresión logística.

El tercer modelo clásico, XGBoost, se ajustó igualmente mediante búsqueda aleatoria. La Tabla 6 recoge la configuración seleccionada.

Tabla 6. Hiperparámetros seleccionados para XGBoost (características agregadas).

Hiperparámetro	Valor seleccionado
n_estimators	600
max_depth	3
learning_rate	0,1
subsample	0,9
colsample_bytree	0,8
gamma	0,1
min_child_weight	5
reg_alpha	1,0
reg_lambda	2,0

Fuente: elaboración propia.

A pesar de alcanzar la mayor exactitud de este bloque, con un valor de 0,389, XGBoost obtuvo el *F1-macro* más bajo, con 0,334. Este contraste se explica por su tendencia a sobre predecir la clase posicional, para la que logra un F1 de 0,513 a costa de las demás.

Esto demuestra por qué la métrica utilizada en este trabajo es el *F1-macro* y no la exactitud.

4.6.MODELOS CLÁSICOS CON CARACTERÍSTICAS TEMPORALES

La representación temporal por fases se evaluó con los dos modelos de conjunto que mejor habían rendido sobre las características agregadas.

En primer lugar, Random Forest, con la configuración recogida en la Tabla 7, alcanzó una exactitud de 0,389 y un *F1-macro* de 0,380.

Tabla 7. Hiperparámetros seleccionados para Random Forest (características temporales).

Hiperparámetro	Valor seleccionado
n_estimators	300
max_depth	None
max_features	log2
min_samples_split	10
min_samples_leaf	8
class_weight	balanced

Fuente: elaboración propia.

La desagregación por fases mejoró el reconocimiento de todas las clases respecto a la versión agregada. La clase dinámica, en particular, pasó de un F1 de 0,261 a 0,303.

Por su parte, XGBoost temporal se ajustó con la configuración mostrada en la Tabla 8.

Tabla 8. Hiperparámetros seleccionados para XGBoost (características temporales).

Hiperparámetro	Valor seleccionado
n_estimators	600
max_depth	3
learning_rate	0,05
subsample	0,7
colsample_bytree	0,9
gamma	0,1
min_child_weight	5
reg_alpha	0,1
reg_lambda	1,0

Fuente: elaboración propia.

Este modelo alcanzó la mayor exactitud de todo el estudio, con un valor de 0,412. Sin embargo, su *F1-macro* se quedó en 0,358, lo que confirma de nuevo su sesgo hacia la clase posicional.

4.7.MODELOS BASADOS EN GRAFOS DE POSICIONES

La representación estructural modela cada partida como una secuencia de grafos de posición. De cada partida se extraen diez instantáneas, o *snapshots*, equiespaciadas a lo largo de toda su duración, de modo que quedan representadas la apertura, el medio juego y el final. Se descarta la posición inicial por ser idéntica en todas las partidas.

Cada instantánea constituye un grafo dirigido en el que los nodos representan las casillas ocupadas, a razón de una pieza por nodo, y las aristas codifican las relaciones de ataque y defensa. Por cada pieza se generan aristas dirigidas hacia las casillas ocupadas que esta ataca. Se distingue entre relación de ataque, cuando la pieza de destino pertenece al rival, y relación de defensa, cuando pertenece al propio jugador.

Cada nodo se describe mediante un vector de trece dimensiones que combina la codificación *one-hot* del tipo de pieza y del color, las coordenadas normalizadas de la casilla, el valor material normalizado de la pieza y sus grados normalizados de ataque y defensa. El empleo de codificación *one-hot* para el tipo de pieza evita que el modelo la interprete erróneamente como una escala ordinal.

El conjunto resultante comprende 9.977 partidas y 99.761 instantáneas

4.7.1. GCN con agregación a nivel de partida

La primera arquitectura basada en esta representación es una red convolucional de grafos, o GCN, que clasifica cada instantánea de forma independiente. Está compuesta por tres capas convolucionales con normalización por lotes y activación ReLU, seguidas de una operación de agregación por media, o *global mean pooling*, que resume cada grafo en un único vector. Sobre este vector, dos capas lineales producen la salida correspondiente a las cuatro clases.

El entrenamiento se realizó minimizando la entropía cruzada ponderada por pesos de clase, calculados como el inverso de la frecuencia de cada estilo.

La predicción de estilo de una partida se obtiene promediando las probabilidades de todas sus instantáneas y seleccionando la clase de mayor probabilidad. Esta agregación constituye el elemento determinante del enfoque, pues traslada la decisión desde la posición individual, escasamente informativa del estilo, hasta la partida completa, que es la unidad efectivamente etiquetada y la misma que emplean los modelos clásicos.

Los hiperparámetros seleccionados mediante búsqueda aleatoria se recogen en la Tabla 9.

Tabla 9. Hiperparámetros seleccionados para el modelo GCN con agregación a nivel de partida.

Hiperparámetro	Valor seleccionado
hidden_dim	128
num_layers	3
lr	0,0005
weight_decay	1e-05
dropout	0,2
batch_size	256

Fuente: elaboración propia.

Sobre la partición de ajuste, el modelo alcanzó a nivel de partida una exactitud de 0,424 y un *F1-macro* de 0,393. Resulta ilustrativo contrastar este valor con el obtenido a nivel de instantánea individual, que se queda en 0,330. La distancia entre ambos valores cuantifica la ganancia derivada de agregar las predicciones al nivel de la partida.

Esta cifra corresponde a la partición de búsqueda de hiperparámetros. La comparación rigurosa frente al resto de familias, sobre un mismo conjunto de prueba y promediando varias semillas, se difiere al apartado 4.9, donde el resultado es más conservador.

4.7.2. GCN temporal con GRU

Con el fin de aprovechar la dimensión temporal del dato, se incorporó una segunda arquitectura que trata la partida como una secuencia ordenada de instantáneas.

En ella, el mismo codificador GCN genera un vector de representación por instantánea. A continuación, una red recurrente de tipo GRU procesa la secuencia resultante, de modo que su estado final alimenta una capa lineal que predice el estilo de la partida. Esta formulación es la que mejor se corresponde con la noción de grafos temporales dinámicos que da título al trabajo.

Con los hiperparámetros recogidos en la Tabla 10, la variante temporal alcanzó sobre la partición de ajuste una exactitud de 0,394 y un *F1-macro* de 0,380, valores muy próximos a los de la arquitectura estática.

Tabla 10. Hiperparámetros seleccionados para el modelo temporal GCN+GRU.

Hiperparámetro	Valor seleccionado
hidden_dim	128
gru_hidden	64
num_layers	3
lr	0,001
dropout	0,2
batch_size	128

Fuente: elaboración propia.

La proximidad entre ambas variantes anticipa una conclusión que el apartado 4.9 confirmará en condiciones equivalentes: la diferencia entre ellas es despreciable frente a su variabilidad, por lo que no cabe atribuir superioridad a ninguna de las dos.

4.8.EXPERIMENTO DE GENERALIZACIÓN ENTRE JUGADORES

Con objeto de evaluar la capacidad de generalización de las representaciones más allá de los jugadores observados durante el entrenamiento, se llevó a cabo un experimento de validación *leave-one-player-out*. En él, los modelos se entrenan con las partidas de tres jugadores y se evalúan sobre el cuarto.

Puesto que el estilo del jugador excluido no aparece durante el entrenamiento, el modelo no puede recuperar su etiqueta exacta. El interés reside, por tanto, en determinar hacia qué estilo conocido se inclinan mayoritariamente sus partidas.

La Tabla 11 resume, para las características agregadas, la predicción mayoritaria de cada modelo ante cada jugador excluido.

Tabla 11. Predicción mayoritaria en la validación *leave-one-player-out* (características agregadas).

Jugador excluido	Estilo real	LR	RF	XGB
Karpov	Posicional	Defensivo (42 %)	Dinámico (38 %)	Táctico (36 %)
Kaspárov	Dinámico	Táctico (42 %)	Táctico (43 %)	Posicional (59 %)
Tal	Táctico	Dinámico (44 %)	Dinámico (48 %)	Posicional (60 %)
Petrosián	Defensivo	Posicional (45 %)	Táctico (44 %)	Posicional (64 %)

Fuente: elaboración propia.

De los tres modelos, la regresión logística ofrece el comportamiento más coherente, en la medida en que cada jugador excluido tiende a asociarse con un estilo próximo al suyo: Karpov se inclina hacia el defensivo, Kaspárov hacia el táctico y Tal hacia el dinámico.

XGBoost, por el contrario, concentra la mayoría de sus predicciones en la clase posicional, lo que lo hace poco informativo en este contexto.

Aunque ningún modelo logra recuperar una etiqueta ausente, algo esperable dada la naturaleza del experimento, las inclinaciones de la regresión logística sugieren que las características empleadas capturan, al menos parcialmente, la proximidad entre estilos.

4.9.COMPARATIVA GLOBAL Y ANÁLISIS DE RESULTADOS

Los apartados anteriores han presentado el rendimiento de cada modelo sobre su propia partición de ajuste. Para establecer una comparación rigurosa entre las tres familias de representación, la Tabla 12 reúne los resultados obtenidos en condiciones equivalentes, esto es, con las mismas partidas de entrenamiento y un mismo conjunto de prueba de 1.965 partidas.

Los modelos de grafos, sujetos a inicialización aleatoria, se reportan como media y desviación típica sobre cinco semillas. Los modelos clásicos, de carácter determinista, se reportan con un único valor. La tabla aparece ordenada de mayor a menor *F1-macro*.

Tabla 12. Comparativa global de modelos en igualdad de condiciones, ordenada por F1-macro.

Modelo	Características	Test F1-macro	Test acc	Test F1-pond.
GNN estática + agregación	Grafos	0,371 ± 0,008	0,388	0,389
XGBoost	Temporal	0,369	0,410	0,391
GNN temporal, GCN+GRU	Grafos	0,369 ± 0,007	0,389	0,387
Random Forest	Temporal	0,365	0,371	0,373
Regresión logística	Agregada	0,362	0,375	0,373
Random Forest	Agregada	0,353	0,359	0,360
XGBoost	Agregada	0,333	0,379	0,357

Fuente: elaboración propia.

Los resultados indican que, sobre un mismo conjunto de datos, la representación basada en grafos es competitiva con los mejores modelos clásicos. La variante estática con agregación obtiene el *F1-macro* medio más alto, con un valor de 0,371. Sin embargo, la diferencia

respecto a XGBoost con características temporales, que alcanza 0,369, es muy inferior a la desviación típica. Por tanto, ambos resultados deben considerarse equivalentes.

Cabe destacar que la representación en grafo alcanza este nivel partiendo directamente de la estructura del tablero, sin recurrir a características diseñadas de forma manual. No puede afirmarse, sin embargo, que los grafos superen al conjunto de los modelos clásicos, ya que esa diferencia solo aparece en ejecuciones aisladas con semillas favorables y desaparece al promediar varias ejecuciones.

En primer lugar, la tarea resulta intrínsecamente difícil. Con cuatro clases, el azar sitúa el *F1-macro* en torno a 0,25, mientras que los mejores modelos apenas alcanzan 0,37. Esto confirma que las señales de estilo, aunque presentes, son débiles y se solapan, tal como anticipaba el análisis exploratorio.

Es interesante la evolución de la representación en grafo. En su versión original constituía el peor de los modelos, con un *F1-macro* de 0,268, próximo al azar. Tras el rediseño de la representación y la adopción de la predicción a nivel de partida, ha pasado a situarse al nivel de los mejores modelos.

El factor determinante de esta mejora no residió en el ajuste de los hiperparámetros, sino en tres decisiones de modelado: el empleo de todas las partidas y de todas las fases del juego, la definición de características de nodo adecuadas y, sobre todo, la formulación de la predicción al nivel de la partida, coherente con el hecho de que el estilo es una propiedad de la partida y no de una posición aislada.

En segundo lugar, la dimensión temporal aporta una mejora apreciable en los modelos clásicos, cuyas variantes por fases superan a las agregadas. En cambio, entre las dos variantes de grafo la diferencia es despreciable.

XGBoost temporal alcanza la mayor exactitud del estudio, con 0,410, pero no el mejor *F1-macro*, debido a su tendencia a sobrepredecir la clase mayoritaria. Esto justifica la elección del *F1-macro* como criterio principal de evaluación.

Por último, las confusiones más comunes se producen entre los pares estilísticamente más próximos: el dinámico y el táctico, por un lado, y el posicional y el defensivo, por otro. Además, la clase dinámica es la peor reconocida por todos los modelos.

5. CONCLUSIONES Y TRABAJO FUTURO

5.1. CONCLUSIONES

Este Trabajo Fin de Estudios ha abordado el aprendizaje de estilos de juego en ajedrez como una tarea de clasificación supervisada, planteada sobre partidas reales de cuatro jugadores asociados a estilos de referencia. Frente a enfoques centrados en el rendimiento del juego, el trabajo se ha orientado al análisis del comportamiento y ha comparado, en igualdad de condiciones, tres formas de representar una partida: una representación agregada, una representación temporal por fases y una representación estructural basada en grafos de posiciones.

Esta comparación, con base en el *F1-macro* como criterio principal, constituye la aportación central de la memoria.

Los cuatro objetivos específicos planteados se han cubierto a lo largo del desarrollo. Se construyó un conjunto de datos de partidas históricas en formato PGN a partir de jugadores con perfiles diferenciados, del que se extrajeron tres representaciones complementarias (agregada, temporal por fases y estructural en grafos); se implementaron y optimizaron modelos clásicos de clasificación, como regresión logística, Random Forest y XGBoost; se diseñaron y evaluaron dos arquitecturas de redes neuronales sobre grafos —una red convolucional, o GCN, con agregación a nivel de partida, y un modelo temporal que combina la GCN con una red recurrente GRU—, comparadas con los modelos clásicos en igualdad de condiciones; y se analizaron las ventajas y limitaciones de cada representación.

Todas las familias se compararon sobre las mismas particiones y con las mismas métricas. Además, el estudio se complementó con un experimento de generalización entre jugadores.

El resultado principal es que, sobre exactamente los mismos datos, la representación basada en grafos resulta competitiva con los mejores modelos clásicos, aunque sin superarlos de forma estadísticamente significativa. El modelo de grafos con agregación a nivel de partida obtuvo el mejor *F1-macro* medio, con un valor de 0,371, en empate estadístico con el mejor modelo clásico, XGBoost sobre características temporales, que alcanzó un *F1-macro* de 0,369. La diferencia entre ambos resultados es muy inferior a la desviación típica.

Es interesante este resultado porque la representación en grafo alcanza ese nivel partiendo directamente de la estructura del tablero, sin características diseñadas de forma manual. Conviene subrayar la evolución de este enfoque: en su versión inicial, la red sobre grafos era el peor de los modelos, con un *F1-macro* próximo al azar, de 0,268. Tras el rediseño de la representación, mejoró.

Esta mejora se dio gracias a tres decisiones de modelado: emplear todas las partidas y todas las fases del juego, definir características de nodo adecuadas y, sobre todo, trasladar la predicción al nivel de la partida, que es la unidad realmente asociada al estilo.

El estudio deja además varias observaciones de interés. La incorporación de la dimensión temporal mejora el rendimiento de los modelos clásicos respecto a las representaciones agregadas, mientras que entre las dos variantes de grafo la diferencia es despreciable.

El contraste entre exactitud y *F1-macro* se mostró revelador: el modelo de mayor exactitud no fue el de mejor *F1-macro*, debido a su tendencia a favorecer la clase mayoritaria. Esto justifica la elección del *F1-macro* como criterio principal en un problema con clases desbalanceadas.

El experimento de generalización entre jugadores, por su parte, sugirió que las características capturan parte de la proximidad entre estilos, ya que el modelo lineal tendía a asociar cada jugador excluido con un estilo adyacente al suyo.

No obstante, el trabajo también evidencia limitaciones importantes. Las señales asociadas al estilo son débiles y se solapan entre clases. Con cuatro clases, los mejores modelos apenas superan un *F1-macro* de 0,37 frente a un azar situado en torno a 0,25, y las confusiones más persistentes se producen entre los pares estilísticamente más próximos.

A ello se añade una limitación de diseño: como cada jugador aporta un único estilo, la etiqueta de estilo coincide en la práctica con la identidad del jugador, lo que condiciona la interpretación de los resultados.

El estilo de juego en ajedrez no puede describirse únicamente mediante estadísticas agregadas, sino que requiere considerar también la evolución temporal de la partida y la estructura interna de las posiciones.

A pesar de no haber obtenido buenos resultados en términos absolutos, los experimentos muestran una mejora clara al incorporar la dimensión temporal en los modelos clásicos y, sobre todo, al rediseñar la representación basada en grafos, que pasó de ser el peor modelo a situarse al nivel de los mejores. Queda, por tanto, un amplio margen para seguir investigando en esta dirección, como se recoge en las líneas de trabajo futuro.

5.2. LÍNEAS DE TRABAJO FUTURO

El trabajo abre varias vías de continuación. La más inmediata consiste en separar el estilo de la identidad del jugador, incorporando varios jugadores por cada estilo de referencia. De este modo, los modelos podrían aprender el estilo como una propiedad general y no como un rasgo individual. Esto permitiría evaluar la generalización de forma más rigurosa que en el experimento actual de exclusión de jugadores.

En cuanto a la representación en grafos, existe margen para enriquecerla más allá de las relaciones de ataque y defensa. Podrían incorporarse otros tipos de aristas, como movilidad, control de casillas, seguridad del rey o estructura de peones. También sería interesante explorar arquitecturas más expresivas, como las redes de atención sobre grafos.

En la línea del título del trabajo, resultaría natural profundizar en modelos de grafos temporales dinámicos específicos, que integren de forma más estrecha la estructura de cada posición y su evolución a lo largo de la partida, en lugar de combinar una GCN y una GRU como módulos separados.

Por último, sería valioso ampliar y diversificar el conjunto de datos, incorporando más jugadores, más partidas y distintos niveles de juego. También sería conveniente avanzar en la interpretabilidad de los modelos basados en grafos, de manera que no solo clasifiquen el estilo, sino que ayuden a explicar qué rasgos estructurales lo caracterizan.

Estas perspectivas sitúan la representación estructural como una base prometedora para el análisis computacional del estilo ajedrecístico.

Declaración de uso de Inteligencia Artificial generativa

Para la elaboración de este Trabajo Fin de Estudios se han utilizado herramientas de inteligencia artificial generativa únicamente como apoyo en la redacción, es decir, para mejorar la expresión escrita, la claridad y la corrección gramatical y ortográfica del texto. El contenido, los resultados y las conclusiones del trabajo son fruto del trabajo propio del autor.

Referencias bibliográficas

- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16) (pp. 785–794). Association for Computing Machinery. <https://doi.org/10.1145/2939672.2939785> ACM Digital Libraryarxiv
- Fey, M., & Lenssen, J. E. (2019). Fast graph representation learning with PyTorch Geometric. ICLR Workshop on Representation Learning on Graphs and Manifolds. <https://arxiv.org/abs/1903.02428> arXivBibSonomy
- Fiekas, N. (s. f.). python-chess: A chess library for Python [software]. <https://github.com/niklasf/python-chess>
- Kazemi, S. M., Goel, R., Jain, K., Kobyzev, I., Sethi, A., Forsyth, P., & Poupart, P. (2020). Representation learning for dynamic graphs: A survey. Journal of Machine Learning Research, 21(70), 1–73. <https://jmlr.org/papers/v21/19-447.html> arxiv
- Levene, M., & Fenner, T. (2009). A methodology for learning players' styles from game records. arXiv. <https://arxiv.org/abs/0904.2595>
- McIlroy-Young, R., Sen, S., Kleinberg, J., & Anderson, A. (2020). Aligning superhuman AI with human behavior: Chess as a model system. In Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '20) (pp. 1677–1687). Association for Computing Machinery. <https://doi.org/10.1145/3394486.3403219> arxiv
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830. <https://arxiv.org/abs/1201.0490> ACM Digital LibraryJMLR
- PGN Mentor. (s. f.). Base de datos de partidas de ajedrez [conjunto de datos]. Recuperado el 25 de junio de 2026, de <https://www.pgnmentor.com/>
- Rigaux, T., & Kashima, H. (2024). Enhancing chess reinforcement learning with graph representation. arXiv. <https://arxiv.org/abs/2410.23753>
- Rossi, E., Chamberlain, B., Frasca, F., Eynard, D., Monti, F., & Bronstein, M. (2020). Temporal graph networks for deep learning on dynamic graphs. arXiv. <https://arxiv.org/abs/2006.10637>

- Silver, D., Hubert, T., Schrittwieser, J., Antonoglou, I., Lai, M., Guez, A., Lanctot, M., Sifre, L., Kumaran, D., Graepel, T., Lillicrap, T., Simonyan, K., & Hassabis, D. (2017). Mastering chess and shogi by self-play with a general reinforcement learning algorithm. arXiv. <https://arxiv.org/abs/1712.01815>

Anexo A. Código fuente y datos analizados

El código fuente desarrollado durante este Trabajo Fin de Estudios, junto con los conjuntos de datos utilizados en el análisis, se encuentra disponible en la siguiente carpeta de Google Drive:

[https://drive.google.com/drive/folders/1-8q2TRUZb7o-7SCVf8fF8aFMSBq-](https://drive.google.com/drive/folders/1-8q2TRUZb7o-7SCVf8fF8aFMSBq-kgU1?usp=sharing)

[kgU1?usp=sharing](https://drive.google.com/drive/folders/1-8q2TRUZb7o-7SCVf8fF8aFMSBq-kgU1?usp=sharing)El autor de este trabajo es el único autor del código y el único propietario de dicha carpeta.